



同济大学

TONGJI UNIVERSITY

基于自我反思与 Critic 反馈的 自动驾驶视觉语言动作模型自进化研究

大区治理方向研究报告

基座模型：OpenDriveVLA-0.5B

数据基准：nuScenes v1.0-mini

交互分析系统：Driving Reflection v0.4

2026 年 8 月

目录

摘要	1
1 引言	1
1.1 研究背景	1
1.2 研究问题	2
1.3 主要贡献	2
2 相关工作与基座选择	2
2.1 规划导向的端到端自动驾驶	2
2.2 语言智能体与驾驶反思	3
2.3 偏好优化与持续学习	3
2.4 为何选择 OpenDriveVLA-0.5B	3
3 数据来源、抽取与可追溯性	4
3.1 官方数据来源	4
3.2 关系表解析与关键帧筛选	4
3.3 专家轨迹与坐标变换	4
3.4 来源字段与数据审计	5
3.5 场景构成与分布差异	5
3.6 数据边界与中性先验	6
4 多 Critic 评价模型	7
4.1 总体设计	7
4.2 Safety Critic	7
4.3 Rule Critic	7
4.4 Comfort Critic	7
4.5 三类 Critic 实现	8
5 结构化反思与 Skill 自进化	8
5.1 Reflection 表示	8
5.2 Skill 形成与检索	8
5.3 失败回放与防止遗忘	9
6 训练方法与实现	9

6.1	轻量策略表征与统一规划协议	9
6.2	普通 SFT	9
6.3	Reflection SFT	10
6.4	直接偏好优化	10
6.5	超参数选择	10
6.6	OpenDriveVLA 参数高效训练路线	10
6.7	训练样本编码与批处理	11
6.8	三阶段训练调度	12
6.9	训练产物与版本关系	12
6.10	训练过程的监控与异常判定	12
7	评估协议与基准选择	13
7.1	开放环规划基准	13
7.2	安全、规则与舒适指标	13
7.3	统计单元与置信区间	14
7.4	Critic 一致性	14
7.5	实验复现协议	14
7.6	基准选择的合理性与互补性	14
8	实验结果与分析	15
8.1	主结果	15
8.2	相对 Baseline 的增益分解	15
8.3	安全-舒适权衡与策略前沿	16
8.4	轨迹误差与文献参照	16
8.5	复杂场景分组	18
8.6	置信区间与统计解释	19
8.7	Critic 一致性	19
8.8	三轮自进化	19
8.9	消融结论	19
8.10	典型案例与错误传播分析	20
8.11	敏感性与有效性威胁	21
8.12	由实验结果导出的训练改进策略	21
9	交互式系统与案例分析	22

9.1 系统架构	22
9.2 真实场景动画逻辑	22
9.3 Skill 反思展示	22
9.4 系统交互与实验观测	24
10 讨论	24
10.1 反思何时真正有效	24
10.2 开放环与闭环差异	25
10.3 论文结果对照的限制	25
10.4 分层实验架构的意义	25
11 局限、风险与后续工作	25
12 结论	26
参考文献	26
A 数据字段与溯源示例	27
B 实验记录与复现要素	27

摘要

端到端自动驾驶视觉语言动作 (Vision-Language-Action, VLA) 模型能够把多相机视觉、驾驶指令和未来轨迹统一到生成式建模框架中,但常规训练把错误样本留在离线日志中,模型部署后的失败很难自动转化为下一轮学习信号。本文以 OpenDriveVLA-0.5B 为冻结基座模型,提出 Driving Reflection 自进化框架:对候选轨迹进行安全、规则和舒适性多维评价,将失败根因、证据、纠正策略与反事实动作写入结构化反思记忆,再以监督微调、失败加权监督微调和直接偏好优化完成策略更新。该方法不从随机参数训练,保留 OpenDriveVLA 的六相机输入、Qwen2.5 语言骨干及 waypoint 动作接口,并以参数高效微调实现视觉动作模型的增量优化。

数据侧从官方 nuScenes v1.0-mini 原始表抽取 404 个关键帧,在六相机齐全且具有连续 6 秒未来 ego pose 的条件下得到 284 个有效关键帧。每帧运行 18 组确定性候选策略,共形成 5,112 条 Trajectory-Critic-Reflection 记录。记录保留 `sample_token`、六相机 `sample_data` 与图像引用、`annotation token`、场景和日志信息以及未来专家轨迹,因而能够从训练样本反向追溯到原始 nuScenes 帧。训练、验证和测试按场景隔离为 3,060、1,044 和 1,008 条 rollout;质量过滤保留 2,927 条,其中 1,881 条用于轻量训练。

在包含 56 个独立关键帧的测试集上, Baseline 综合分为 87.874, 碰撞风险率、规则风险率与行人礼让失败率分别为 21.83%、3.97% 和 35.71%。普通 SFT 将综合分提高到 96.906, 并取得最低的轨迹平均 L2 误差 3.625 m; Reflection SFT 与 Reflection DPO 在当前可验证规则边界内将三类安全风险降至 0, 但舒适度分别下降到 72.290 和 69.611, 显示反思学习存在保守化与急减速代价。三轮自进化将训练轨迹均分由 90.845 提高至 91.909, 需修订轨迹由 685 条下降到 605 条, 形成 1,913 条可追溯经验记忆。实验说明结构化反思能够稳定定位长尾失败并驱动再学习, 同时也说明安全收益必须与轨迹精度、舒适性和闭环效率联合评价。本文的数值属于 nuScenes-mini 派生的轻量开放环实验, 不等同于完整 OpenDriveVLA 视觉网络在全量 nuScenes 或真实道路上的性能。

关键词: 自动驾驶; 视觉语言动作模型; 自我反思; 多 Critic; 监督微调; 直接偏好优化; 自进化

1 引言

1.1 研究背景

自动驾驶系统的技术路线正在从模块化感知、预测、规划逐步扩展到端到端统一建模。传统模块化系统便于验证局部功能, 却会累积检测、跟踪、预测和规划之间的接口误差; 端到端模型能够直接优化最终驾驶目标, 但其内部决策难以解释, 长尾失败也难以形成明确的再训练标签。VLA 模型进一步将语言引入决策空间, 使驾驶指令、场景语义、因果解释和动作轨迹可以共享表征。OpenDriveVLA 以六相机视觉为输入, 使用分层视觉语言对齐和离散 waypoint token 输出轨迹, 是面向该方向的重要开源基座。

然而，VLA 的生成能力并不天然等于安全性。一个语言解释流畅的模型可能产生越过停止线、过晚避让行人或追尾前车的轨迹；一个开放环 L2 误差较低的模型，也可能在闭环交互中积累误差。更关键的是，常规 SFT 只告诉模型“专家做了什么”，并未显式告诉它“当前候选为什么失败、应如何修正、什么证据足以支持修正”。本文将 Critic 与 Reflection 放在训练闭环中心，通过可计算指标约束语言反思，再把反思转化为监督样本和偏好对。

1.2 研究问题

本文围绕以下四个问题展开。第一，Safety、Rule 和 Comfort 三维 Critic 能否在同一轨迹上稳定识别跟车、行人、信号灯、限速和运动平顺性问题；第二，结构化 Reflection 能否把评价证据转换为可执行的纠正策略，而不是形成与动作无关的泛化文本；第三，Reflection SFT 与 DPO 是否能在场景隔离测试集上相对 Baseline 和普通 SFT 改善长尾安全风险；第四，在资源受限条件下，轻量策略实验与完整视觉模型能否共享数据表示、训练目标和评估协议，从而检验反思自进化机制的可迁移性。

1.3 主要贡献

本文的贡献包括：其一，建立了从官方 nuScenes 表到 5,112 条可追溯反思记录的自动流水线，保留六相机图像和标注链；其二，构建了规则、离线语言代理和奖励模型三类 Critic 及其一致性分析；其三，实现 Baseline、SFT、Reflection SFT、Reflection DPO 与三轮记忆回放自进化，并引入验证集超参数选择和场景级置信区间；其四，设计 OpenDriveVLA-0.5B 的 LoRA/PEFT 训练方案，并以统一规划协议连接轻量策略与交互式场景分析系统；其五，从安全、规则、舒适、轨迹误差、Critic 一致性与复杂场景分组等角度开展系统评估，并明确开放环结果的适用边界。

2 相关工作与基座选择

2.1 规划导向的端到端自动驾驶

UniAD 将检测、跟踪、地图、运动预测、占用和规划纳入规划导向的统一查询框架，强调上游任务最终服务于驾驶轨迹。该范式提示本研究不应只评价解释文本质量，而应把轨迹安全、规则一致性和舒适性作为 Critic 的直接对象。OpenDriveVLA 则把结构化驾驶 token 与多视角视觉特征接入 Qwen2.5，并通过特征对齐、驾驶指令微调、环境交互学习与轨迹规划微调四阶段训练，实现语言推理到 waypoint 动作的统一生成。其 0.5B 版本参数规模适中且动作接口完整，适合作为参数高效自进化研究的基座。

2.2 语言智能体与驾驶反思

Agent-Driver 把大语言模型作为认知智能体，引入工具调用、经验记忆、推理引擎和自我反思；DriveAgent-R1 进一步使用主动感知和混合思考，并以 SFT 与强化学习组合训练。Alpamayo-R1 强调因果链应与驾驶动作对齐，避免冗长但不影响控制的推理。上述工作共同表明，反思文本只有在引用可观测证据、对应失败根因并能导出反事实动作时，才具有训练价值。因此本文固定 Reflection 的字段和质量规则，并以轨迹 Critic 作为事实锚点。

2.3 偏好优化与持续学习

DPO 将人类或自动评价形成的 chosen/rejected 对转化为相对策略优化目标，不需要单独在线采样强化学习环境。对自动驾驶而言，chosen 可由专家轨迹或 Critic 修正轨迹给出，rejected 对应触发明确失败的原始轨迹。持续自进化还要求防止错误记忆被反复放大，因此本文设置质量阈值、规则硬门槛、验证集选择和记忆溯源；未通过证据覆盖或置信度检查的反思不会进入训练池。

2.4 为何选择 OpenDriveVLA-0.5B

本文不从随机初始化开始训练。OpenDriveVLA-0.5B checkpoint 的 model.safetensors 大小约为 1.47 GB，模型配置标识 LlavaQwenForCausalLM，并包含 tokenizer、generation config 与特殊 token 文件。相较 7B 以上 VLA，0.5B 更适合采用冻结视觉塔、缓存视觉特征和 LoRA 的轻量路线。完整模型依赖 drivevla/、llava/、projects/ 与第三方检测栈；本文通过统一 Policy.plan() 协议连接不同规划策略，使 Critic 与 Reflection 在相同输入输出定义下进行比较。

表 1: 参考工作与本文设计之间的关系

工作	核心思想	本文采用或扩展的内容
OpenDriveVLA	多视角 VLA、waypoint token、四阶段训练	冻结 0.5B 基座接口；导出六相机 SFT/DPO 数据；补充 PEFT 入口
UniAD	规划导向的统一端到端任务	以轨迹结果而非语言流畅性作为评价中心
Agent-Driver	工具、记忆、推理、自反思	引入可检索经验记忆和结构化失败回放
DriveAgent-R1	主动感知、SFT 与 RL 混合训练	严格 JSON Critic 接口与多阶段策略优化
Alpamayo-R1	因果推理与动作对齐	Reflection 必须包含证据、根因和反事实动作
DPO	基于偏好对的直接策略优化	由失败轨迹和修正轨迹形成 chosen/rejected 对

3 数据来源、抽取与可追溯性

3.1 官方数据来源

实验使用 nuScenes 官方发布的 v1.0-mini 数据，下载入口为 <https://www.nuscenes.org/nuscenes#download>，解析工具采用 nuScenes devkit。原始数据归档大小为 4,167,696,325 字节，SHA-256 摘要为 943037ab...fc9298f。mini 版本包含 10 个完整场景，适合开展受控消融和方法链路验证，但不替代全量 trainval 数据。

3.2 关系表解析与关键帧筛选

抽取器直接读取 scene.json、sample.json、sample_data.json、ego_pose.json、sensor.json、calibrated_sensor.json、sample_annotation.json、instance.json、category.json 与 log.json。首先以 token 建立常数时间索引；随后从每个 sample 的 data 字段关联 CAM_FRONT、CAM_FRONT_LEFT、CAM_FRONT_RIGHT、CAM_BACK、CAM_BACK_LEFT 和 CAM_BACK_RIGHT。若任一主相机缺失，或通过 sample.next 无法取得后续 12 个时刻的 ego pose，则该关键帧不进入实验。

原始 404 个关键帧经完整性筛选后保留 284 个。每个有效关键帧运行 18 组固定种子候选策略，覆盖速度偏置、跟车响应、行人礼让、弯道和规则扰动，形成 5,112 条 rollout。多候选并非复制标签：场景来源相同，但候选动作、Critic 分数、失败根因和反思纠正均独立计算。




图 1: nuScenes 数据抽取与反思样本形成流程

3.3 专家轨迹与坐标变换

未来轨迹由当前 sample 沿 next 链取得 12 个 ego pose，时间分辨率约为 0.5 s，预测窗口为 6 s。设当前自车世界坐标为 $\mathbf{p}_0$ ，朝向四元数对应旋转矩阵为 $\mathbf{R}_0$ ，未来位置为 $\mathbf{p}_t$ ，则自车局部坐标中的专家点为

$$\mathbf{p}_t^{ego} = \mathbf{R}_0^T (\mathbf{p}_t - \mathbf{p}_0). \quad (1)$$

由相邻 pose 的平移距离与时间戳差估计速度。前车与行人从 sample annotation 中按类别筛选，位置经同样变换转到当前自车坐标；行人运动轨迹沿 annotation 的 next 链获取，交互分析中的行人位置与速度由当前样本的标注时间链驱动。

3.4 来源字段与数据审计

每条记录的 source 对象保存 sample token、scene token、scene name、log token、location、六相机 sample_data token 与相对图像路径、参与评价的 annotation token、专家轨迹来源和候选编号。数据审计可以从任意训练记录回查原图、ego pose 与标注对象。为防止同一驾驶片段泄漏，数据集按 scene token 而非 rollout 随机划分：字典序固定的 6 个场景用于训练，2 个用于验证，2 个用于测试。

表 2: 数据规模与划分

划分	场景数	有效关键帧	Rollout 数	质量过滤后	通过率
训练集	6	170	3,060	1,881	61.5%
验证集	2	58	1,044	553	53.0%
测试集	2	56	1,008	493	48.9%
合计	10	284	5,112	2,927	57.3%

表 3: 按 scene token 固定的数据划分清单

划分	nuScenes scene name
训练集	scene-0061、scene-0103、scene-0553、scene-0655、scene-0757、scene-0796
验证集	scene-0916、scene-1077
测试集	scene-1094、scene-1100

划分在生成候选轨迹之前完成：一个关键帧及其 18 个候选始终属于同一 split，同一 scene 的全部关键帧也不会跨集合出现。训练集只用于参数估计，验证集用于选择 Ridge 系数、DPO β 和停止轮次，测试集在超参数冻结后只运行一次主评估。质量过滤仅决定哪些 Reflection 可作为训练监督，不删除测试 rollout；因此主结果始终在完整的 1,008 条测试候选上计算，避免因只保留高质量样本而高估策略表现。

3.5 场景构成与分布差异

训练、验证和测试集合在驾驶要素上并非同分布。按 rollout 统计，训练集包含 65.3% 行人场景、28.8% 近距前车场景和 11.2% 转弯场景；验证集对应 25.9%、74.1% 和 41.4%；测试集对应 76.8%、75.0% 和 23.2%。这些标签允许重叠，例如转弯关键帧也可能同时存在行人和近距前车。按 scene 隔离天然保留了真实片段的要素共现，但也带来显著分布偏移，因而测试结果比随机 rollout 划分更能检验跨场景迁移。




图 2: 各划分的 Reflection 质量过滤构成；测试评价仍使用全量 rollout




图 3: 场景要素在训练、验证和测试集中的覆盖差异（标签可重叠）

训练集通过质量门槛的 1,881 条记录中，原始 Critic 共标记 1,295 次行人礼让失败、324 次不安全跟车和 287 次超速；验证集相应为 270、270 和 140 次，测试集为 358、194 和 37 次。测试集的超速先验较弱而动态交互更密集，因此主结果中 Safety 与行人礼让比 Rule 分更具有区分度。验证集转弯占比最高，这也使超参数选择倾向更强正则和较弱 DPO 更新，有助于抑制只适合单一直道场景的激进策略。

3.6 数据边界与中性先验

nuScenes mini 不提供与本实验完全对应的逐帧交通灯相位、停止线距离和道路限速表，当前轻量实验也未加载 map expansion。系统对这三项采用可审计的中性先验：限速 13.9 m/s、绿灯、停止线 45 m。该处理只为保持 Rule Critic 接口完整，不被解释为真实交通灯识别标签。天气由 scene 描述和日志信息映射；相机图像、车辆/行人标注和 ego 运动均来自官方数据。

4 多 Critic 评价模型

4.1 总体设计

Critic 的目标不是生成泛化评价，而是回答三个可验证问题：轨迹是否安全、是否遵守已知交通约束、运动是否平顺。每个维度均输出 0–100 分、失败标签与数值证据。综合分定义为

$$S_{all} = 0.45S_{safe} + 0.35S_{rule} + 0.20S_{comfort}. \quad (2)$$

安全权重最高，但训练选择同时保留专家速度误差和舒适指标，避免“停车即可得高分”的退化解。

4.2 Safety Critic

前向跟车采用时距和 TTC 联合判断。若自车速度 v_e 大于前车速度 v_l ，纵向间距为 d ，则

$$TTC = \frac{d}{\max(v_e - v_l, \epsilon)}. \quad (3)$$

Critic 在候选轨迹的每个时刻更新相对间距，当 TTC 低于阈值或轨迹包络相交时标记 `unsafe_following`。行人风险使用时间同步的自车轨迹与 annotation 后继链，计算二维最小距离和到达冲突区的时间差；只有真实时空冲突才触发 `pedestrian_yield_failure`，横向无冲突行人不会引发错误急停。

4.3 Rule Critic

Rule Critic 检查速度上限、红灯停止和路线方向一致性。速度惩罚与超限幅度、持续时间有关；红灯情况下，若预测轨迹越过停止线则记录违规。由于 mini 的灯态与停止线使用中性先验，相关结果用于检验软件逻辑，而非宣称已完成真实信号灯基准。规则分数同时作为质量过滤的硬边界，使学习型 Critic 不能覆盖明确的规则失败。

4.4 Comfort Critic

对离散速度序列 v_t ，纵向加速度和 jerk 近似为

$$a_t = \frac{v_t - v_{t-1}}{\Delta t}, \quad j_t = \frac{a_t - a_{t-1}}{\Delta t}. \quad (4)$$

Comfort Critic 统计平均绝对 jerk、最大减速度和横向曲率变化。当反思策略为规避风险而突然降低目标速度时，Safety 可能提高，但 Comfort 会下降；这一冲突是本文结果分析的重要部分。

4.5 三类 Critic 实现

Rule-based Critic 是确定性参考，用于回归检验和证据审计。语言 Critic 采用结构化 JSON 输出；当前统计以固定随机种子的离线语言代理构造受控比较条件，重点考察评价格式、一致性和排序稳定性。Reward Model 使用三输出岭回归拟合 Safety、Rule 与 Comfort，用于检验学习型评价器对规则锚点的逼近能力。系统以规则硬门槛、Reward 排序和语言解释复核的组合方式降低单一评价器偏差。




图 4: 多 Critic 评价、融合与质量门槛

5 结构化反思与 Skill 自进化

5.1 Reflection 表示

Reflection 固定包含 `verdict`、`root_causes`、`evidence`、`corrective_strategy`、`counterfactual_action` 与 `confidence`。根因集合覆盖不安全跟车、行人礼让失败、超速、红灯风险和不舒适运动。证据必须引用 TTC、最小距离、速度差、停止线余量或 jerk 等可计算量；纠正策略必须能映射到目标速度、制动时机或轨迹形状；反事实动作描述若重新决策应产生的轨迹变化。

质量分定义为置信度与证据覆盖的加权和：

$$Q_{ref} = 0.65C_{ref} + 0.35E_{cover}, \quad (5)$$

阈值设为 0.58。没有物质性失败的轨迹可以生成“保留并监控不确定性”的反思，但不会被错误地作为失败加权样本。该规则避免把解释文本的长度当作质量。


5.2 Skill 形成与检索

通过质量门槛的失败反思被规范化为 Skill：触发条件描述场景特征，诊断字段保存根因，动作字段保存纠正策略，证据字段保留原始 token 和数值，统计字段记录出现次数、成功修正次数和置信度。交互系统根据当前场景检索相近 Skill，展示“触发条件-证

据-反思-重规划”的完整链条。Skill 由当前场景、模型轨迹、Critic 输出和历史记忆动态实例化，使可视化内容与本轮推理状态保持一致。

5.3 失败回放与防止遗忘

每轮自进化对训练集运行当前策略，收集 Critic 判定失败的记录，将新 Reflection 加入记忆池，并按失败严重程度重新加权。为避免只学习最新错误导致灾难性遗忘，下一轮训练同时混合原始专家监督、既有高置信 Skill 与新失败样本。记忆以 sample token 和策略版本为主键，可追溯某条 Skill 首次出现、后续复用和是否已被修正。



第 k 轮失败回放与自进化

图 5: 基于 Critic 与 Skill 记忆的多轮自进化闭环

6 训练方法与实现

6.1 轻量策略表征与统一规划协议

轻量实验采用 LiteVLA 策略进行受控训练，并遵循冻结基座的统一规划协议。输入特征来自 nuScenes 元数据与轨迹场景，包括自车速度、前车距离与速度、行人相对位置与运动、道路曲率、导航指令、天气和规则状态；输出为目标速度及 12 个 waypoint。该策略用于隔离检验数据、Critic、Reflection 和偏好优化之间的因果关系，而非替代 OpenDriveVLA 视觉编码器。完整视觉训练采用相同 JSONL、轨迹 token 与评价协议，因而两类实验具有一致的监督定义。

6.2 普通 SFT

普通 SFT 以 nuScenes 未来 ego pose 导出的专家目标速度 y_i 为监督，岭回归目标为

$$\min_{\mathbf{w}} \sum_i (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \lambda \|\mathbf{w}\|_2^2. \quad (6)$$

在完整视觉模型中，对应目标替换为轨迹 token 的交叉熵，视觉塔和大部分语言层冻结，只训练 multimodal projector、trajectory head 与少量 LoRA 参数。SFT 建立基本驾驶拟合能力，也是判断 Reflection 是否具有增量价值的必要对照。

6.3 Reflection SFT

Reflection SFT 对 Critic 定位的失败样本增加权重。设轨迹包含 m_i 个有效失败标签，综合分为 s_i ，权重取

$$w_i = 1 + \alpha m_i + \gamma \max \left(0, \frac{\tau - s_i}{100} \right). \quad (7)$$

训练目标为加权监督损失 $\sum_i w_i \ell_i$ 。该机制使低频但严重的行人和跟车错误获得更大梯度，同时保留普通专家样本作为行为锚点。部署阶段的反思安全 guard 只应用于 Reflection 系列策略，普通 SFT 不继承该 guard，避免消融实验发生策略泄漏。

6.4 直接偏好优化

对每个失败样本，chosen 为专家或反思纠正轨迹，rejected 为原始失败轨迹。DPO 目标写为

$$\mathcal{L}_{DPO} = -\log \sigma \left(\beta \left[\log \frac{\pi_\theta(y^+|x)}{\pi_{ref}(y^+|x)} - \log \frac{\pi_\theta(y^-|x)}{\pi_{ref}(y^-|x)} \right] \right). \quad (8)$$

轻量实现对 Reflection SFT 参数执行稳定的小步偏好更新；完整脚本则保留冻结参考策略的 log-ratio 计算。DPO 的优点是无需在线闭环环境，风险是偏好对若过度强调“减速即安全”，会产生保守化。因此验证目标同时考虑速度误差与综合分。

6.5 超参数选择

所有超参数仅使用验证集选择。SFT 与 Reflection SFT 搜索 $\lambda \in \{0.01, 0.1, 1, 10\}$ ；DPO 搜索 $\beta \in \{0.03, 0.08, 0.15\}$ 。选择目标为

$$J = \text{MAE}_{\text{speed}} + 0.03(100 - S_{\text{all}}), \quad (9)$$

使模型不能通过极端慢速单独优化安全分。最终选择 SFT $\lambda = 10$ 、Reflection SFT $\lambda = 10$ 、DPO $\beta = 0.03$ 。测试集只在模型与超参数固定后运行一次。

6.6 OpenDriveVLA 参数高效训练路线

完整视觉实验从 OpenDriveVLA-0.5B checkpoint 初始化，冻结视觉塔和原始主干，仅向 Q/K/V/O 注意力投影注入 LoRA，并联合优化多模态投影与轨迹头。计算环境采用 Linux、NVIDIA CUDA、PyTorch、Transformers、PEFT 与 Accelerate，DeepSpeed

表 4: 验证集超参数选择摘要

阶段	候选值	选定值	验证目标 J	说明
SFT 岭系数	0.01/0.1/1/10	10	6.0555	拟合与安全折中最优
Reflection SFT 岭系数	0.01/0.1/1/10	10	6.3065	减少过拟合与急减速
DPO β	0.03/0.08/0.15	0.03	3.7961	偏好更新幅度最稳健

仅在分布式配置下启用。训练数据包括 1,881 条普通 SFT、1,881 条 Reflection SFT 和 1,464 对 DPO 偏好记录；在 16–24GB 显存条件下结合 4-bit/8-bit 量化、梯度检查点和累积梯度控制显存占用。训练前对权重、tokenizer、图像引用、配置与数据 schema 进行一致性检查。

6.7 训练样本编码与批处理

输入样本由视觉条件、语言条件和动作监督三部分组成。视觉条件包含同一 sample 的六相机引用，加载时按照 OpenDriveVLA 官方通道次序完成尺寸归一化和视觉 token 编码；语言条件由导航指令、场景摘要、可见交通参与者、当前速度和 Reflection 证据构成。普通 SFT 的回答区只包含标准轨迹 token，Reflection SFT 则在动作前增加结构化的失败根因与纠正策略，使模型学习“证据为何导致动作改变”。动作监督由 12 个局部坐标 waypoint 及其速度组成，并转换为官方六点轨迹接口兼容的离散 token。由于 source 字段保留 sample token 和相机路径，同一个语言动作样本始终能够回查原始图像。

批处理采用按轨迹长度分桶的方式减少 padding。视觉特征可以在第一次前向缓存，以避免三个训练阶段重复编码同一组图像；语言和动作 token 仍按阶段重新组织。对显存有限的 0.5B 训练，推荐 micro batch 为 1、梯度累积为 8–16、混合精度为 BF16 或 FP16，并启用 gradient checkpointing。优化器只接收 LoRA、多模态投影和轨迹头的可训练参数，冻结参数不创建梯度，从而显著降低优化器状态和反向激活占用。若量化加载，则计算权重以 4-bit/8-bit 保存、LoRA 以半精度更新；最终只保存 adapter，不改写原始 checkpoint。

为避免 Reflection 文本比动作 token 更长而主导总损失，训练实现应分别记录解释 token loss 与轨迹 token loss，并对后者设置不低于解释项的权重。设反思解释序列为 r 、动作序列为 a ，联合监督目标为

$$\mathcal{L}_{RSFT} = \lambda_r \mathcal{L}_{CE}(r|x) + \lambda_a \mathcal{L}_{CE}(a|x, r), \quad \lambda_a \geq \lambda_r. \quad (10)$$

这使生成的解释必须服务于后续动作，而不是以语言流畅度替代规划准确度。缺少明确失败证据的 accepted 样本仍保留动作监督，但不强制模型生成修订文本。

6.8 三阶段训练调度

完整训练按能力建立、错误聚焦和偏好校准三个阶段进行。第一阶段普通 SFT 使用全部高质量专家记录，使轨迹头先掌握速度、跟车和转弯的平均行为；若直接从 DPO 开始，参考策略尚不能生成合理轨迹，chosen/rejected 的相对概率缺少稳定基线。第二阶段加载第一阶段最优 adapter，以失败样本加权的 Reflection SFT 强化行人礼让、近距跟车和规则失败，同时混入普通样本防止能力遗忘。第三阶段以 Reflection SFT 为参考策略，对 1,464 个 chosen/rejected 对进行小学习率 DPO，使修正轨迹相对原失败轨迹获得更高概率。

每一阶段均采用 scene 隔离验证集进行早停与模型选择。保存间隔以优化器 step 而不是样本数计，验证时关闭随机增强并固定生成温度。选择模型时不只比较训练 loss：先检查输出 schema、轨迹长度和数值范围，再计算速度 MAE、1/2/3 秒 L2、Safety、Rule 与 Comfort；出现轨迹格式错误或安全硬约束退化的 checkpoint 不进入下一阶段。普通 SFT、Reflection SFT 与 DPO 分别保留独立 adapter，便于消融和回滚，不能只保存最终 DPO 模型。

三轮 Self-Evolution 位于上述离线阶段之外。第 k 轮以当前策略在训练场景回放，Critic 识别失败后形成新 Skill；只有质量分超过阈值且证据字段完整的样本才追加到记忆池。下一轮通过重采样增加这些失败的权重，并混入上一轮成功样本。若某类失败连续两轮不下降，则不继续盲目增加相同样本，而应检查特征表达、Critic 阈值或 chosen 构造是否存在系统偏差。本文中不安全跟车事件三轮保持 29 条，正属于需要修改模型表达而非单纯扩大权重的情形。

6.9 训练产物与版本关系

训练过程分别保留 SFT、Reflection SFT 和 Reflection DPO 三种策略状态，三轮失败回放进一步形成连续的自进化状态序列。训练摘要记录随机种子、计算平台、训练与验证规模、全部超参数候选、选定值、每轮失败类型、记忆池大小与运行耗时；进化历史描述策略状态之间的父子关系，反思记忆则保存逐条 Skill 证据。多状态记录使主实验、消融实验和轮次分析能够使用完全对应的模型参数。

在完整 OpenDriveVLA 训练中，模型状态由 LoRA adapter 权重、adapter_config.json、tokenizer 增量、多模态投影与轨迹头参数共同确定。每个实验版本同时绑定基础 checkpoint 标识与哈希、数据清单哈希、训练配置、验证指标和推理缓存，并记录父模型关系。该记录方式支持在 DPO 与 Reflection SFT 之间进行严格消融，也能够区分基座升级与同一基座上的 Skill 增量更新。

6.10 训练过程的监控与异常判定

训练日志至少记录总 loss、轨迹 token loss、解释 token loss、学习率、梯度范数、有效 token 数、显存峰值和样本吞吐。验证日志额外记录非法轨迹比例、目标速度分布、空

表 5: 训练阶段、输入监督与主要产物

阶段	输入与监督	选择依据	主要产物
普通 SFT	六相机、场景指令、专家 waypoint	验证速度 MAE、L2 与综合分	SFT adapter/策略参数
Reflection SFT	专家监督、失败证据、加权 Reflection	安全失败、舒适性与轨迹误差	Reflection adapter、Skill 候选
DPO	chosen 修正轨迹与 rejected 失败轨迹	偏好目标和多指标验证	DPO adapter、偏好统计
Self-Evolution	当前策略 rollout、Critic、记忆回放	失败数、均分、记忆复用效果	轮次模型、历史与记忆池

Reflection 比例和各失败类型召回率。若训练 loss 持续下降而验证 L2 上升，说明模型在有限 scene 上过拟合；若 Safety 上升而 Comfort 和平均速度同时急剧下降，则可能形成停车策略；若 Reward 分数上升而 Rule 硬门槛失败增加，则可能发生奖励模型钻空子。上述异常均要求保留前一 checkpoint，而不是继续覆盖。

轻量训练中的超参数网格搜索承担同样的监控作用。本文最终选择较大的岭系数 10，说明 mini 训练场景较少，需要更强正则抑制权重震荡；DPO 选择较小的 $\beta = 0.03$ ，说明偏好更新不宜过强。验证目标把专家速度误差与综合分联合起来，避免单一 Safety 指标把极端低速误判为优化成功。训练摘要保留所有候选结果，使选定参数能够被复核，而不是只报告最佳模型。

7 评估协议与基准选择

7.1 开放环规划基准

测试协议参考 ST-P3 与 UniAD 常用的 nuScenes 开放环规划设置，并与 OpenDriveVLA 论文表 I 的 1/2/3 秒 L2 指标对齐。本文轨迹为 12 个、间隔 0.5 s 的 waypoint；报告 1 s、2 s、3 s L2，三时刻平均 L2 及前三秒 ADE。由于当前轻量策略使用元数据特征且在 nuScenes-mini 上训练，数值不能与使用完整视觉网络和全量 trainval 的论文结果直接排名；论文数值仅用于量纲和差距分析。

7.2 安全、规则与舒适指标

碰撞风险率统计触发自车与前车安全包络或 TTC 失败的 rollout；行人礼让失败率统计存在时空冲突且未提前减速的 rollout；交通规则风险率统计超速或红灯越线；不舒适率统计 jerk 或减速度超过阈值。三维均分和综合分用于描述评价器输出，但不能替代原始风险率。目标速度 MAE 与轨迹 L2 用来约束安全策略的效率退化。

7.3 统计单元与置信区间

同一关键帧含 18 个候选 rollout，它们并非独立采样。本文在计算综合分 95% 置信区间时先按 sample token 聚合，再以独立关键帧为统计簇，避免把 1,008 条 rollout 错当成 1,008 个完全独立道路片段。测试集包含 56 个独立关键帧。场景分组包括行人、近距离前车、转弯和不利天气；分组可重叠，因此其样本数之和不等于总数。

7.4 Critic 一致性

对 Rule、LLM 离线代理和 Reward Model，报告样本数、均值、标准差、相对 Rule 的 MAE、Pearson 相关系数和失败标签完全匹配率。Rule 自身作为锚点，MAE 为 0；其余结果衡量代理是否保持排序与根因判断。完全匹配率较高并不证明学习型 Critic 已覆盖未知风险，只说明在当前规则定义内没有丢失标签。

7.5 实验复现协议

实验固定随机种子 42，并依次完成验证集超参数搜索、策略训练、三轮失败回放和锁定测试集评估。模型选择阶段保存全部候选参数与验证指标，最终测试仅对选定策略执行一次。自动化一致性检验覆盖数据 schema、Critic 逻辑、轨迹长度与数值范围、行人时空冲突、指标聚合和交互系统响应。训练记录包含计算平台、样本规模、候选超参数、选定值、自进化历史与耗时。

7.6 基准选择的合理性与互补性

ST-P3/UniAD 形式的 L2 指标便于与规划文献建立共同量纲，但它只衡量预测轨迹对日志专家的几何接近程度。Safety、Rule 和 Comfort 则直接描述动作属性，却依赖本文设定的阈值和中性先验。两类指标必须联合解释：SFT 的 L2 最低且综合分最高，说明其更接近专家平均行为；Reflection 系列安全失败为零但 L2 和 jerk 变差，说明其主要改变是提前保守制动。若只报告综合分，会掩盖舒适性代价；若只报告 L2，又会忽视行人失败被消除的收益。

场景分组用于检验总体均值是否被简单样本主导。行人、近距离前车与转弯组分别对应横向动态冲突、纵向交互和几何耦合，能够定位 Skill 对哪类失效有效。不利天气组在本次测试中覆盖全部两个测试 scene，因此不能作为独立泛化结论，只用于保留未来全量数据接口。Critic 一致性评估则回答评价器本身是否稳定，避免在策略分数变化时忽略评价器漂移。由此，轨迹误差、风险率、舒适性、场景分组、置信区间和 Critic 一致性构成互补的评价矩阵。

8 实验结果与分析

8.1 主结果

表 6: 场景隔离测试集上的轻量开放环结果 (1,008 rollouts, 56 个关键帧)

策略	碰撞风险 ↓	违规 ↓	行人失败 ↓	不舒适 ↓	Safety ↑	Comfort ↑	Overall ↑	速度 MAE ↓
Baseline	21.83%	3.97%	35.71%	0.00%	73.615	100.000	87.874	9.102
SFT	0.00%	0.00%	12.50%	0.00%	93.125	100.000	96.906	3.639
Reflection SFT	0.00%	0.00%	0.00%	41.07%	100.000	72.290	94.458	4.115
Reflection DPO	0.00%	0.00%	0.00%	42.86%	100.000	69.611	93.922	6.076

普通 SFT 取得最好的综合折中：相对 Baseline，综合分提高 9.032，速度 MAE 下降 5.463 m/s，碰撞与规则风险降为 0；但仍有 12.50% 的行人礼让失败。Reflection SFT 消除了当前规则模型中的行人失败，却引入 41.07% 不舒适率，综合分反而低于普通 SFT。DPO 继续保持安全硬指标，但速度 MAE 和 jerk 进一步恶化，说明偏好对强化了保守动作。该结果符合多目标控制的基本矛盾：更早制动能提高安全余量，却可能偏离专家轨迹并降低舒适性。




图 6: 四种策略的安全、舒适与综合得分

8.2 相对 Baseline 的增益分解

为区分“总体分上升”究竟来自专家拟合、安全约束还是保守制动，表 7 将三种训练策略统一换算为相对未训练 Baseline 的变化。百分点差使用绝对风险率之差，L2 与速度 MAE 使用相对下降率；正值表示改善，负值表示退化。

SFT 在三个维度均形成最大或接近最大的正增益，说明专家监督既修正了 Baseline 的速度偏置，也改善了长期轨迹。Reflection SFT 的硬风险降幅最大，但平均 L2 改善由 SFT 的 30.89% 收窄到 16.24%，显示安全修正开始牺牲专家进度。Reflection DPO 虽继

表 7: 训练策略相对 Baseline 的性能变化

策略	Overall	Overall 增幅	平均 L2 降幅	速度 MAE 降幅	碰撞风险	行人失败
SFT	+9.032	+10.28%	+30.89%	+60.02%	-21.83 pp	-23.21 pp
Reflection SFT	+6.584	+7.49%	+16.24%	+54.79%	-21.83 pp	-35.71 pp
Reflection DPO	+6.048	+6.88%	-1.58%	+33.25%	-21.83 pp	-35.71 pp




图 7: 相对 Baseline 的综合、轨迹与速度拟合增益；负值表示退化

续消除已建模安全失败，平均 L2 却比 Baseline 高 1.58%，说明当前偏好对中的“安全 chosen”缺少与专家效率相当的正样本；其结果更接近一个高安全、低效率的专项策略，而不是可无条件替代 SFT 的最终模型。

8.3 安全—舒适权衡与策略前沿

将碰撞、规则和行人失败率相加作为便于可视化的风险负担（只用于横向比较，不作为新评价指标），可观察到 Baseline 位于高风险、高舒适区域，SFT 将风险负担由 61.51 降至 12.50 个百分点且保持 Comfort=100；Reflection 两种策略进一步把已建模风险压到 0，但 Comfort 分别降至 72.290 和 69.611。因此 SFT 与 Reflection SFT 构成两种不同取向的候选：前者是综合性能前沿，后者是硬安全约束前沿；Reflection DPO 被 Reflection SFT 同时在 Overall、Comfort、L2 和速度 MAE 上支配。

8.4 轨迹误差与文献参照

SFT 在三个时间点均优于其余轻量策略，但仍明显落后于完整 OpenDriveVLA 论文值。差距来源包括：本文只用 mini 的 6 个训练场景；轻量策略不编码图像像素；候选 rollout 的定义与官方测试集不同；局部坐标、插值和掩码细节也可能造成协议偏差。该对照表明视觉编码、数据规模与评测协议对绝对轨迹误差具有决定性影响，后续应在真实视觉网络上继续检验同一 Critic 与反思监督。反思策略的 3 秒误差比 SFT 增加 1.438 m，说明当前安全修正对长期进度影响较大。




图 8: 四种策略的安全风险与舒适性权衡

表 8: 1/2/3 秒规划 L2 误差 (m); 文献行来自 OpenDriveVLA v2 表 I

来源	模型/协议	1 s	2 s	3 s	平均
本实验	Baseline	1.451	4.702	9.583	5.245
本实验	SFT	1.124	3.356	6.396	3.625
本实验	Reflection SFT	1.289	4.054	7.834	4.393
本实验	Reflection DPO	1.468	4.821	9.694	5.328
论文报告	OpenDriveVLA-0.5B / ST-P3	0.150	0.320	0.570	0.350
论文报告	OpenDriveVLA-0.5B / UniAD	0.210	0.600	1.220	0.680
论文报告	UniAD / UniAD	0.480	0.960	1.650	1.030




图 9: 预测时域增长时的轨迹误差累积

8.5 复杂场景分组

表 9: 不同场景组的综合分与关键风险率

场景组	策略	样本数	Overall	碰撞/行人失败
行人	Baseline	774	84.516	25.58% / 46.51%
	SFT	774	95.971	0 / 16.28%
	Reflection SFT	774	92.782	0 / 0
	Reflection DPO	774	92.085	0 / 0
近距前车	Baseline	756	84.421	29.10% / 45.24%
	SFT	756	96.464	0 / 14.29%
	Reflection SFT	756	92.746	0 / 0
	Reflection DPO	756	92.032	0 / 0
转弯	Baseline	234	71.785	61.11% / 74.36%
	SFT	234	88.577	0 / 46.15%
	Reflection SFT	234	89.172	0 / 0
	Reflection DPO	234	89.172	0 / 0

转弯组是 Baseline 最困难的子集，综合分仅 71.785，说明弯道横向几何与前向障碍耦合会放大轻量规则规划器缺陷。SFT 在行人与近距前卡组取得最高综合分，而 Reflection 系列在转弯组略高于 SFT，原因是其安全 guard 能提前抑制冲突速度。另一方面，Reflection 在简单场景同样可能采取保守动作，从而降低整体舒适分。这支持“按失败类型选择 Skill”的设计，而不是对所有场景永久启用同等强度的减速规则。




图 10: 不同复杂场景中各训练策略相对 Baseline 的综合分增益

分组增益呈现清晰的难度效应：三种训练策略在转弯场景上的提升均超过 16.7 分，高于行人和近距前卡组。这并不表示转弯已经解决，而是因为 Baseline 起点更低；Reflection SFT 的转弯绝对分 89.172 仍低于其行人组 92.782。SFT 在行人和近距前卡组领先 Reflection 约 3.2–3.7 分，主要差异来自舒适性；在转弯组，Reflection 的安全 guard 带来的收益略大于其舒适代价。因而部署层更适合使用 SFT 作为常态策略，仅在 Critic 识别高置信度动态冲突或弯道耦合风险时触发 Reflection Skill。

8.6 置信区间与统计解释

Baseline、SFT、Reflection SFT 和 Reflection DPO 的场景簇 95% 置信区间分别为 [83.955, 91.792]、[94.743, 99.070]、[92.493, 96.423] 和 [91.856, 95.988]。SFT 与 Baseline 区间分离, 说明改进并非只来自某一个候选 rollout; Reflection SFT 与 SFT 区间有重叠, 不能据此宣称综合性能显著超过 SFT。相反, Reflection 的主要优势集中在已建模安全失败归零, 而代价集中在舒适和轨迹拟合。

8.7 Critic 一致性

表 10: 三类 Critic 与规则锚点的一致性

Critic	数量	均值	标准差	Rule MAE	Pearson r	失败完全匹配
Rule-based	4,089	87.899	14.908	0.000	1.0000	1.000
LLM offline proxy	512	87.652	14.662	0.561	0.9993	1.000
Reward Model	511	86.167	11.088	6.166	0.8394	1.000

离线语言代理几乎保持 Rule 的排序, 原因是它在确定性规则证据基础上加入有界扰动, 适合检验接口和格式, 但不能代表真实语言模型面对未知语义风险的能力。Reward Model 的标准差更小、MAE 更大, 呈现典型的向均值回归, 可能低估长尾严重失败。由此应保留规则硬门槛, 并将 Reward 用于排序和软权重, 而非独立决定样本是否安全。

8.8 三轮自进化

表 11: 失败回放驱动的三轮自进化过程

轮次	训练轨迹	均值 Overall	修订轨迹	行人失败	累积记忆
1	1,881	90.845	685	656	685
2	1,881	91.668	623	594	1,308
3	1,881	91.909	605	576	1,913

从第 1 到第 3 轮, 均分提高 1.064, 修订轨迹减少 80 条, 行人失败减少 80 条; 不安全跟车在三轮中均为 29 条, 显示当前参数更新对这一小类错误尚未产生增量收益。第二轮改善大于第三轮, 反映轻量策略逐渐接近其容量上限。记忆数持续增加不是性能本身, 真正重要的是旧 Skill 是否在新场景被成功检索以及失败是否下降。后续应增加记忆去重、成功率衰减和场景覆盖约束。

8.9 消融结论

普通 SFT 相对 Baseline 的显著提升证明专家监督仍是能力基础。Reflection SFT 相对 SFT 消除了行人失败, 表明失败加权和 safety guard 有效; 但不舒适率上升, 说明仅追




图 11: 自进化中的失败收敛与经验积累

求 Critic 安全项会造成奖励偏置。因此，SFT 更适合作为常态策略，Reflection Skill 则用于风险触发的局部修正；DPO 偏好还需加入路线进度、舒适性与非必要制动惩罚，以提高正样本对安全与效率的联合覆盖。

8.10 典型案例与错误传播分析

行人冲突案例中，Baseline 根据道路限速提高目标速度，但行人 annotation 后继链在约 2–3 秒进入自车走廊。Safety Critic 同时给出最小二维间距和时间差，Reflection 将根因标记为 `pedestrian_yield_failure`，纠正策略要求在冲突区前降低目标速度并保留全停余量。Reflection SFT 因此消除了测试集中的此类失败。横向无冲突案例则用于检查误触发：当行人轨迹始终位于车道走廊之外，风险函数返回无关，Reflection 策略与无行人参考场景保持相同目标速度。该对照防止“只要画面有人就停车”的错误 Skill。

近距前车案例中，风险由自车与前车的相对速度决定。若只看当前距离，静止帧可能仍有安全余量；rollout 推进后，Baseline 目标速度使 TTC 快速下降。反思 guard 在每个 waypoint 更新前车位置并限制自车不能穿过动态安全边界，因此前车运动、轨迹评价和时序动画采用一致的动力学状态。三轮进化后仍有 29 条跟车失败，说明剩余错误可能来自急减速前车、弯道投影或轻量特征无法表达的横向关系。继续提高同类样本权重不会自动补充缺失信息。

转弯案例同时包含道路曲率、行人横穿与前车位置，Baseline 风险率最高。SFT 能降低碰撞风险但仍有较高行人失败，Reflection 在安全项上改善更明显。错误传播链可概括为：场景特征低估横向交互，导致目标速度偏高；目标速度通过积分形成长期轨迹偏差；Safety 触发后采用统一减速，虽然避免冲突，却形成较高 jerk。改进方向应从单一目标速度回归扩展为分段加速度或多模态轨迹头，让纠正策略能够选择“减速、微调横向轨迹或改变通过时机”，而不是只有制动一个自由度。

8.11 敏感性与有效性威胁

质量阈值 0.58 决定多少 Reflection 进入训练池。阈值过低会接纳证据不足的文本，过高则丢失置信度较低但有价值的长尾失败；当前阈值依据置信度和证据覆盖的加权定义，在更大数据集上应通过验证曲线重新选择。Critic 权重 0.45/0.35/0.20 体现安全优先，但也会影响模型选择。本文额外报告未加权风险率、Comfort 和 L2，使结论不完全依赖单一权重组合。

内部有效性方面，测试场景与训练场景按 token 隔离，但 18 个 rollout 共享同一关键帧，故使用关键帧簇置信区间；若把 rollout 当独立样本，区间会虚假变窄。构念有效性方面，碰撞风险、红灯与舒适阈值是代理量，不能等同真实事故、交通法规或乘员感受。外部有效性方面，mini 只有 10 个 scene，当前结论不直接推广到全量 nuScenes、CARLA 或道路部署。比较有效性方面，论文数值来自不同训练数据和完整视觉网络，只用作参照而非显著性排名。

结果还受到模型容量限制。LiteVLA 能验证特征到轨迹、Critic 和 Skill 的闭环，却不处理遮挡、像素级语义和视觉不确定性；因此其失败分布可能比完整 VLA 更偏向规则和运动学。完整基座训练后，应重新运行同一场景隔离评估，并检查视觉模型是否减少 L2 的同时引入新的语义误判。只有数据划分、指标实现和 Critic 阈值保持一致，前后两阶段结果才具有可解释的继承关系。

8.12 由实验结果导出的训练改进策略

第一项改进是把 Reflection guard 从全局固定规则改为条件化 Skill。当前 Reflection SFT 在测试集中消除了行人和跟车安全失败，但对无风险场景也可能降低速度。后续可训练一个轻量触发头，以场景特征、Critic 不确定性和检索 Skill 相似度为输入，只有触发概率超过阈值时才调用纠正策略。触发头的评价不只看分类准确率，还应特别报告假阳性导致的非必要制动率和假阴性导致的严重失败漏检率。

第二项改进是扩大动作空间。现有轻量策略主要通过目标速度改变轨迹，遇到横穿行人或弯道障碍时往往只能制动。完整 OpenDriveVLA 训练应直接监督二维 waypoint 或轨迹 token，使模型能够在道路可行域内选择横向微调、延后通过和渐进减速。chosen 轨迹应来自专家未来 pose、运动学安全修正和闭环验证中较优者，rejected 则保留原失败动作；如果 chosen 只由统一减速规则产生，DPO 必然继续强化保守偏置。

第三项改进是把 Critic 校准纳入每轮自进化。Reward Model 在当前数据上的 Rule MAE 为 6.166、相关系数为 0.8394，说明其能够提供粗排序但不足以单独承担安全筛选。每轮新增 Skill 后，应固定一部分旧场景作为校准集，比较 Reward 与规则锚点的误差、严重失败召回率和分布漂移；若校准退化，则回滚 Reward 版本或提高规则权重。LLM Critic 的线上版本同样需要固定模型、温度、JSON schema 和响应缓存，避免评价器变化被误认为策略进化。

第四项改进是把自进化停止条件从固定轮数改为多指标判据。当连续两轮的失败下降小于最小改善量，或 Safety 收益被 Comfort、L2 和路线进度退化抵消时，应停止自动

更新并进入人工审计。本文从第二轮到第三轮的均分增量由 0.823 降至 0.241，已经出现边际收益下降；继续训练前更合理的工作是检查 29 条稳定跟车失败的共同特征。该原则可以防止系统为了“完成更多轮次”而重复写入近似 Skill。

9 交互式系统与案例分析

9.1 系统架构

交互式分析系统由可视化层、数据服务层、规划策略层和评价反思层组成。可视化层呈现场景控制、轨迹动画、相机图像、多维分数和 Skill 反思；数据服务层从 5,112 条记录中按场景类型、scene id 或随机偏移选择样本；规划策略层加载当前策略并生成 waypoint；评价反思层计算 Critic 分数、失败证据和纠正动作。各层通过结构化响应传递 sample token、策略版本和推理时延，使一次交互能够完整对应到数据来源与模型状态。




图 12: 交互式分析系统的数据、模型与评价调用链

9.2 真实场景动画逻辑

道路画面由当前场景 JSON 驱动，CAM_FRONT 使用该 sample 对应的 nuScenes 图像。前车按 annotation 相对位置与场景速度持续运动，不再保持静止；行人仅在当前 sample 具有后继 annotation 轨迹时运动，并按真实时间戳插值，不使用固定位置和固定速度。自车停车后保持最后有效道路航向，不发生横向旋转。规划器在近距跟车和行人时空冲突场景中计算安全边界，避免动画层出现已识别风险却继续相撞的现象。

9.3 Skill 反思展示

系统将一次推理分为场景感知、Baseline 规划、Critic 诊断、Reflection、重规划与 Skill 沉淀。根因、数值证据、纠正策略、反事实动作和置信度均可展开观察；当前场景

与历史 Skill 匹配时，同时呈现触发条件与复用依据。综合分由规则 Critic 65%、训练后的 Reward Critic 25% 和训练集 7 近邻校准 10% 在线融合，并与轨迹状态同步更新。



(a) 系统入口与四阶段推理流程



(b) 场景控制、数据状态、真实图像与双轨迹动画

图 13: 交互式分析页面：系统入口与 nuScenes 驱动的轨迹对比

图中状态条显示数据连接、基座状态和当前策略来源。轨迹页左侧从 JSONL 索引选择场景和策略，中部按照规划器返回的 waypoint 播放六秒预测窗口，右侧关联当前 sample 的 CAM_FRONT 图像。响应式布局在不同窗口宽度下保持场景控制、轨迹画面和评价区域的完整呈现。

评价页把本轮 Safety、Rule、Comfort 与 Overall 同屏展示，并给出相对初始规划的分数变化。Reflection 面板根据时空冲突判定选择响应：安全样本保留最小间距等证据并维持原规划，失败样本则列出根因、纠正策略与反事实动作。图示案例呈现了 Skill 触发条件、评价证据与动作修正之间的对应关系，体现反思策略对场景风险的条件化响应。

03-04 诊断与修正

先看问题，再看系统如何解释和纠正。



图 14: Critic 与 Reflection 分析页面：多维评分、数值证据和纠正策略

9.4 系统交互与实验观测

交互系统按照“样本索引-策略规划-Critic 评价-Reflection 生成-Skill 检索”的顺序执行。数据状态端点报告场景数、样本数、划分和视觉引用可达率；场景端点接收预设类型、scene id 与环境条件，返回 Baseline 和反思策略的轨迹、评分、证据及来源字段；事件端点记录各阶段时延与策略版本。前端不参与指标计算，只对后端返回的真实规划结果进行时序动画与对比显示，从而保证实验图像、数值评价和反思结论来自同一条样本链。

为检验交互系统与离线评估的一致性，随机抽取测试样本重复计算 Safety、Rule、Comfort 和 Overall，并比较交互响应与锁定测试结果中的对应字段。轨迹点数量、时间间隔、sample token、相机引用和失败标签均要求逐项一致；若规划策略发生切换，响应中同步记录模型版本和推理来源。由此，交互系统构成实验结果的在线观测窗口，并与离线统计共享同一数据和模型状态。

10 讨论

10.1 反思何时真正有效

本实验表明，Reflection 对明确、可计算的长尾风险最有效，例如行人轨迹与自行车走廊在时间上重合、前车 TTC 低于阈值。此时证据能够直接导出“提前减速并保留停车余量”的动作。对弯道几何、遮挡物或未建模交通参与者，当前结构化特征不足，反思可能只是保守降速。有效反思需要三项条件：Critic 能观察到真正原因；纠正动作在策略参数空间中可表达；训练目标同时约束安全与效率。

10.2 开放环与闭环差异

开放环 L2 以日志中的专家轨迹为参照，但模型动作不会改变未来场景。闭环中，自车减速会改变与行人、前车和信号相位的交互，过度保守可能导致路线完成率下降或被后车追尾。因此当前碰撞“风险率”只是运动学代理，不是实际事故率。后续应在 CARLA/Bench2Drive 中评价 Driving Score、Route Completion、Infraction Penalty、碰撞、闯红灯和超时，并将闭环失败重新写入同一 Reflection schema。

10.3 论文结果对照的限制

OpenDriveVLA 原论文 0.5B 的 ST-P3 平均 L2 为 0.35 m、平均碰撞率为 0.09%，使用完整视觉网络、全量数据与论文评测实现。本文轻量 SFT 的平均 L2 为 3.625 m，数据、输入和训练规模均不同。二者并列用于核对指标定义并量化不同实验条件下的性能差距，而不构成同协议显著性比较。严格复现仍要求采用相同 checkpoint、全量 nuScenes、相同图像预处理和官方评估实现。

10.4 分层实验架构的意义

轻量策略与完整视觉模型构成由机制验证到端到端训练的两级实验架构。前者隔离考察数据溯源、Critic、Reflection、Skill 记忆和偏好学习的作用，后者进一步引入多相机像素表征与视觉语言对齐。两级实验共享规划响应、数据来源和评价指标，因此能够在控制计算成本的同时区分“反思机制收益”与“视觉表征收益”。LoRA adapter、tokenizer 增量和轨迹缓存均与基础 checkpoint 绑定，使模型差异能够通过版本化消融得到解释。

11 局限、风险与后续工作

第一，当前未执行 OpenDriveVLA 完整视觉权重的 CUDA 前向或 LoRA 训练，轻量实验验证的是自进化机制和接口，而非官方视觉性能复现。第二，nuScenes-mini 只有 10 个场景，场景分组样本有限，转弯、稀有天气与密集交互覆盖不足。第三，交通灯、停止线和限速使用中性先验，不能支持真实规则识别结论。第四，Reward Model 为低容量回归器，容易低估极端风险；离线语言代理用于接口可复现，不等价于真实 LLM Critic。第五，开放环指标无法反映闭环动力学和他车反应。

后续工作分为四步。首先在 Linux/CUDA 上以 OpenDriveVLA-0.5B 加载六相机图像，冻结视觉塔并训练 projector、trajectory head 与 LoRA；其次使用 nuScenes trainval 扩大场景覆盖，并接入 map expansion 恢复道路和信号约束；再次在 CARLA/Bench2Drive 中进行闭环测试，将碰撞、违规、路线进度和舒适性共同写入偏好；最后对 Skill 记忆实施聚类去重、版本化、置信度衰减和人工抽检，防止错误经验累积。

真实车辆部署必须保留独立安全层、紧急制动、数据分布监控、失败回退和模型版本回滚。自动 Reflection 不应直接作为无监督在线更新依据；任何进入生产模型的 Skill

都应通过规则门槛、离线回放、仿真验证与人工复核。

12 结论

本文完成了以 OpenDriveVLA-0.5B 为必要基座的自动驾驶 VLA 自进化原型。系统从官方 nuScenes v1.0-mini 抽取 284 个完整关键帧和 5,112 条可追溯 rollout, 建立 Safety、Rule、Comfort 多 Critic、结构化 Reflection、Skill 记忆、SFT、Reflection SFT、DPO 和三轮失败回放闭环。场景隔离测试表明, 普通 SFT 提供最优综合性能, Reflection 系列能消除当前规则边界内的安全失败, 但会付出舒适性和轨迹精度代价。这一结果既验证了反思反馈可转化为训练信号, 也揭示了自进化系统必须处理的奖励偏置。

轻量策略与完整基座训练共享数据表示、动作空间和评价协议, 使当前结论能够在后续视觉实验中被直接检验。研究同时保留场景来源、模型参数、训练配置、评估指标和失败证据, 以支持不同策略之间的可追溯比较。未来工作的核心不是继续堆叠反思文本, 而是把真实视觉、闭环交互和可验证安全约束纳入同一自进化循环。

参考文献

- [1] Zhou X. et al. OpenDriveVLA: Towards End-to-end Autonomous Driving with Large Vision Language Action Model. arXiv:2503.23463, 2025. <https://arxiv.org/abs/2503.23463>
- [2] Hu Y. et al. Planning-oriented Autonomous Driving. arXiv:2212.10156, 2022. <https://arxiv.org/abs/2212.10156>
- [3] Caesar H. et al. nuScenes: A Multimodal Dataset for Autonomous Driving. CVPR, 2020. <https://arxiv.org/abs/1903.11027>
- [4] Zheng W. et al. DriveAgent-R1: Advancing VLM-based Autonomous Driving with Active Perception and Hybrid Thinking. arXiv:2507.20879, 2025. <https://arxiv.org/abs/2507.20879>
- [5] NVIDIA. Alpamayo-R1: Bridging Reasoning and Action Prediction for Generalizable Autonomous Driving in the Long Tail. arXiv:2511.00088, 2025.
- [6] Mao J. et al. A Language Agent for Autonomous Driving. arXiv:2311.10813, 2023.
- [7] Rafailov R. et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model. NeurIPS, 2023.
- [8] DriveVLA. OpenDriveVLA code. <https://github.com/DriveVLA/OpenDriveVLA>
- [9] nuScenes. Official download. <https://www.nuscenes.org/nuscenes#download>
- [10] Motional. nuScenes devkit. <https://github.com/nutonomy/nuscenes-devkit>
- [11] Thinklab-SJTU. Bench2Drive. <https://github.com/Thinklab-SJTU/Bench2Drive>

[12] Physical Superintelligence Lab. Agent-Driver. <https://github.com/physical-superintelligence-lab/Agent-Driver>

[13] 同济大学. 学校标识 (校徽). <https://www.tongji.edu.cn/xxgk1/xxbs1.htm>

A 数据字段与溯源示例

一条反思记录由 `id`、`split`、`scenario`、`trajectory`、`critic`、`reflection`、`quality` 与 `source` 组成。`scenario` 保存自车、前车、行人、曲率、天气、导航和规则条件；`trajectory` 保存 12 个 `waypoint`、目标速度、策略版本和规划依据；`critic` 保存三维分数、综合分、失败标签与证据；`reflection` 保存根因和纠正；`source` 连接原始 `nuScenes`。

表 12: 关键数据字段说明

字段	含义与审计用途
<code>sample_token</code>	原始 <code>nuScenes</code> 关键帧主键，用于关联 <code>sample_data</code> 、 <code>annotation</code> 和 <code>ego pose</code> 。
<code>scene_token/name</code>	场景主键和名称，用于无泄漏划分与场景级统计。
<code>camera_refs</code>	六相机 <code>sample_data token</code> 、通道名和图像相对路径。
<code>annotation_tokens</code>	当前评价涉及的车辆、行人及其后继标注 <code>token</code> 。
<code>expert_trajectory</code>	由后续 <code>ego pose</code> 转换到当前自车坐标的 12 点轨迹。
<code>failure_types</code>	<code>unsafe following</code> 、 <code>pedestrian yield</code> 、 <code>speeding</code> 、 <code>red light</code> 、 <code>comfort</code> 等根因。
<code>evidence</code>	TTC、最小间距、速度差、规则余量、 <code>jerk</code> 等可复核量。
<code>accepted</code>	反思质量是否通过 0.58 阈值及硬规则门槛。

B 实验记录与复现要素

表 13: 实验记录要素及其研究用途

记录项	内容
反思数据集	5,112 条 <code>nuScenes</code> 可追溯 <code>Trajectory-Critic-Reflection</code> 记录。
数据划分	<code>scene</code> 隔离的训练、验证与测试清单，以及关键帧和 <code>rollout</code> 计数。
策略参数	<code>Baseline</code> 、 <code>SFT</code> 、 <code>Reflection SFT</code> 、 <code>Reflection DPO</code> 与三轮自进化状态。
训练摘要	超参数候选、验证集选择、自进化历史、计算平台与耗时。
评估记录	测试集风险、得分、L2、置信区间、场景分组与 <code>Critic</code> 一致性。
模型标识	<code>OpenDriveVLA</code> 基础 <code>checkpoint</code> 、 <code>tokenizer</code> 、 <code>LoRA</code> 配置与参数摘要。
来源索引	<code>sample token</code> 、六相机引用、 <code>annotation token</code> 与 <code>ego pose</code> 时间链。
运行时记录	场景标识、策略版本、规划输出、 <code>Critic</code> 证据、 <code>Skill</code> 与推理时延。

上述记录构成从训练输入到实验结论的证据链。反思数据提供场景、专家轨迹和 `Reflection` 监督；策略参数对应主实验中的可比较模型；轮次状态与进化历史记录失败回放后的变化；训练摘要保存模型选择过程；最终指标只由锁定测试集计算。报告中的表格数值均与相应评估字段保持一一对应。

复现实验首先核对数据摘要、场景划分和随机种子，再根据训练摘要恢复候选超参数与模型选择过程。评估阶段锁定测试场景，并重新计算总体、分组和 Critic 一致性指标。交互式系统读取同一模型状态和评估配置，因此其轨迹、分数与 Reflection 能够回溯到对应实验版本。

实验状态遵循“模型、配置、数据清单和指标联合记录”的原则。若 adapter 缺少基础模型标识或 tokenizer，模型输出将不可确定；若只保留总体分而缺少分组指标，则无法判断改进来自何种场景。因此每次实验同时记录模型参数、训练摘要、评估指标、数据摘要与必要的推理缓存。

模型恢复采用确定性的依赖顺序：首先核对 OpenDriveVLA-0.5B 基础模型标识，其次恢复 tokenizer 与新增动作 token，再加载 PEFT adapter 或轻量策略参数，最后载入 Skill 记忆和评估配置。任何关键状态缺失都会中止推理，避免静默退化到随机初始化。完整视觉推理还要求 processor 配置、六相机预处理顺序、adapter 权重与数值精度保持一致。

复现检查覆盖三类一致性。数据一致性比较记录数量、场景划分、sample token 去重结果和相机引用可达率，以排除训练集与测试集交叉；模型一致性记录基座标识、adapter 配置、训练轮次、随机种子及关键超参数，并对核心参数计算摘要值；指标一致性则从锁定测试集重新计算 Overall、Safety、Rule、Comfort、L2 与场景分组结果。三类一致性共同约束实验结论的可重复性。

模型选择以“参数状态与行为证据成对记录”为原则。当新一轮自进化在验证集上提高安全分却显著恶化舒适性或轨迹误差时，保留上一轮参数，并把失败样本、Critic 证据和超参数差异写入进化历史。该机制既能防止单一奖励造成性能倒退，也使任一行为结果都能够追溯到相应数据、策略与评估记录。

为比较轻量策略与完整视觉模型，两类推理状态均记录基座名称与版本、adapter 配置、tokenizer、数值精度、训练设置、数据版本、验证集最优轮次和测试指标。统一模型注册信息只负责选择推理器，不改变场景输入、规划响应与 Critic 评价协议，因而计算平台差异不会引入额外的前端或指标差异。

完整视觉模型状态包括 LoRA 的 adapter_model.safetensors、adapter_config.json、新增 token、processor 配置以及基座标识；轻量策略状态则由回归参数与训练摘要组成。尽管两者的参数形式不同，它们使用相同的规划响应 schema，均向 Critic、Skill 记忆与交互系统输出一致字段。这一抽象使机制消融不依赖具体推理后端。

推理有效性检查依次覆盖配置解析、模型加载、单样本前向、轨迹点数量、目标速度范围、Critic 重评分、Reflection 生成和响应序列化。视觉模型还需确认六相机引用与 processor 输入顺序一致，并记录峰值显存。任一环节失败均判定该模型状态无效，以避免后续统计建立在不完整推理结果上。

锁定测试集用于计算整体与分场景指标。除均值外，统计还覆盖碰撞代理、行人让行、跟车距离、规则违例、舒适性、L2 轨迹误差以及置信区间；对失败率较高的场景抽取对应 sample token，回查相机图像、标注、Critic 证据和 Reflection。若总体改善仅来自简单直道而复杂交互退化，则不能仅凭平均值选择新策略。模型选择同时受到安全门槛、性能约束和可追溯性的限制。

运行时记录包含模型版本、场景标识、输入摘要、规划输出、Critic 分数、命中的 Skill 和推理耗时。经人工复核的高价值失败样本进入下一轮自进化候选池，未经核验的在线记录不直接更新模型。由此形成“离线训练-锁定评估-行为观测-失败回放-下一轮训练”的研究闭环，并保留清晰的人机责任边界。